



EchoPulse AI: A Hybrid Local Data Architecture for Multimodal Music Recommendation Integrating WASABI, MSD, and TalkPlay Datasets

John Kennedy Landazuri Sandoval¹, Cristian Camilo Ordonez Quintero¹, Cristian Mendez Rodriguez¹, Hugo Armando Ordoñez Erazo²

[¹ Fundación Universitaria de Popayán, Popayán, Colombia · ² Universidad del Cauca, Popayán, Colombia]

Track: Inteligencia Artificial y Analítica de Datos **ID del artículo:** 22

20CCC'26 · Cartagena de Indias · 12–14 de agosto de 2026

Escuela Naval Almirante Padilla

Contenido

01

Contexto y problema

El sesgo de popularidad concentra atención en éxitos consolidados y limita la visibilidad de artistas emergentes.

02

Método

Arquitectura local multimodal con Triple-Encoder Transformer sobre 5.710 pistas integradas de WASABI, MSD, Lyrics 1950-2019 y TalkPlayData-2.

03

Resultados

Hit@10 = 0.312, ILD +45.3%, EAD +157.9%, latencia sub-250 ms en recuperación.

04

Conclusiones

La afinidad multimodal mitiga el sesgo de popularidad sin sacrificar precisión. Pendiente: validación industrial y estudios online.

01

Contexto y problema

Veremos cómo los algoritmos actuales de recomendación concentran la atención en éxitos consolidados y cómo una arquitectura multimodal basada en contenido puede devolver la visibilidad a los artistas emergentes.

Los sistemas de recomendación musical actuales priorizan la popularidad histórica sobre la afinidad de contenido, creando ciclos de retroalimentación que invisibilizan a los artistas emergentes.

- Según la IFPI, los ingresos globales de música grabada alcanzaron USD 29.6 mil millones en 2024; sin embargo, este crecimiento económico no se traduce proporcionalmente en oportunidades de visibilidad para nuevos creadores en un paisaje digital cada vez más concentrado.
- El filtrado colaborativo, aunque eficaz para contenido establecido, sufre del problema de "cold-start" y exhibe un sesgo de popularidad inherente, lo que refuerza la exposición de éxitos masivos y deja fuera al contenido de nicho.
- La falta de un recomendador multimodal local que evalúe la afinidad intrínseca de la canción (integrando letras, acústica, metadatos y conversación) en lugar de depender de señales de popularidad histórica.



Figura 1. Ciclo de popularidad

Pregunta de investigación o Hipótesis

¿Puede un recomendador musical multimodal local mejorar la diversidad y el descubrimiento de artistas emergentes sin sacrificar precisión?

1

Objetivo general

Diseñar y evaluar un sistema de recomendación musical multimodal local que priorice la afinidad de contenido para mejorar la diversidad y el descubrimiento de artistas emergentes.

2

Objetivos específicos

1. Consolidar datos musicales en una arquitectura local.
2. Entrenar un modelo Transformer con fusión multimodal.
3. Comparar precisión, diversidad, intención y latencia frente a líneas base.

Marco teórico

Transformers para recomendación[Enfoque A]

Vaswani et al., 2017; Sun et al., 2019; Kang & McAuley, 2018.

La autoatención modela secuencias de interacción; BERT4Rec y SASRec mejoran precisión, pero pueden mantener sesgo de popularidad.

Música multimodal y datos locales

Bertin-Mahieux et al., 2011; Tikat et al., 2021; Armbrust et al., 2020.

MSD y WASABI aportan letras, audio y metadatos; el enfoque lakehouse permite reproducibilidad y trazabilidad local.

Recomendación conversacional

Christakopoulou et al., 2016; Gao et al., 2021; Choi et al., 2025.

El lenguaje natural captura intención del usuario; TalkPlayData-2 aporta diálogos estructurados, pero falta evaluación generativa rigurosa.

02

Método

Pipeline local de cinco etapas, integración multimodal y comparación con líneas base.

Diseño metodológico

1

Diseño

Estudio experimental de recomendación multimodal.
Unidad de análisis: pista musical y consulta conversacional.
División temporal 80/10/10 para entrenamiento, validación y prueba.

2

Datos

Fuentes: WASABI, Million Song Dataset, Lyrics 1950-2019 y TalkPlayData-2.
Master Table final: 5.710 pistas con cobertura multimodal.
Incluye 26 características acústicas y aproximadamente 16.000 diálogos.

3

Procesamiento

Limpieza con MICE y detección de atípicos con MAD, $\kappa = 3.5$.
Mapeo de identificadores con algoritmo húngaro.
Modelo Triple-Encoder Transformer con atención cruzada y puntuación híbrida: $\alpha = 0.4$, $\beta = 0.3$, $\gamma = 0.3$.

4

Evaluación

Métricas: Hit@10, MRR, nDCG@10, ILD, EAD, SCS, IAR y RC.
Líneas base: Collaborative Filtering, BERT4Rec, SASRec y TalkPlay.
Evaluación local, con partición temporal y análisis de latencia.

03

Resultados

EchoPulse AI logra precisión competitiva mientras mejora sustancialmente la diversidad y el descubrimiento de artistas emergentes.

Resultados

Model	Hit@10	MRR	nDCG@10	ILD	EAD	SCS	IAR
Collaborative Filtering	0.142	0.089	0.156	0.342	0.127	0.412	0.385
BERT4Rec [4]	0.158	0.095	0.172	0.389	0.145	0.438	0.401
SASRec [3]	0.164	0.102	0.178	0.412	0.168	0.451	0.423
TalkPlay [8]	0.189	0.118	0.165	0.445	0.201	0.623	0.587
EchoPulse AI	0.312	0.165	0.179	0.497	0.327	0.741	0.698




Figura 2. Comparativa EchoPulse AI frente a líneas base

Qué muestra

- **Precisión y diversidad:** Hit@10 = 0.312, ILD = 0.497 (+45.3%), superando a Collaborative Filtering, BERT4Rec, SASRec y TalkPlay.
- **Descubrimiento:** EAD = 0.327 (+157.9%); 32.7% de recomendaciones son artistas emergentes (<10K oyentes).
- **Validación:** Mejoras estadísticamente significativas ($p < 0.001$). Ablación confirma aporte de atención cruzada (+14.1% nDCG@10).

La afinidad multimodal de contenido mitiga el sesgo de popularidad manteniendo precisión competitiva.

Discusión y limitaciones

Qué implica

- La fusión multimodal por atención cruzada proporciona beneficios medibles sobre enfoques de fusión temprana o tardía, validando la arquitectura Triple-Encoder Transformer.
- Plataformas musicales, investigadores y artistas emergentes pueden beneficiarse de recomendadores que equilibren precisión, diversidad y descubrimiento. El 157.9% de mejora en EAD aborda la brecha de visibilidad.
- EchoPulse AI supera a BERT4Rec (Hit@10 = 0.158) y SASRec (Hit@10 = 0.164) al integrar señales multimodales en lugar de solo interacciones históricas.

Qué no cubre

- Validación sobre catálogo curado de 5.710 pistas, subconjunto del paisaje musical global. Escalar a millones de pistas presenta desafíos de ingeniería de datos en entornos locales.
- Evaluación offline con métricas; faltan estudios online con usuarios reales (pruebas A/B) para medir satisfacción percibida.
- El pipeline completo tarda ~6.23 segundos debido a componentes LLM (Qwen 2.5), aunque la recuperación y reordenamiento logran <250 ms.

Conclusiones

1

Demostramos la viabilidad de las arquitecturas de datos locales híbridas y la fusión multimodal (vía Transformers con atención cruzada) para mitigar el sesgo de popularidad y priorizar la afinidad de contenido sin depender de la nube.

2

Logra 45.3% más de Diversidad Intra-Lista y 157.9% más de Descubrimiento de Artistas Emergentes frente a líneas base, manteniendo precisión ($\text{Hit@10} = 0.312$) y capturando mejor la intención del usuario ($\text{SCS} = 0.741$).

3

Escalar a catálogos industriales superando límites de almacenamiento local, mitigar la latencia de $\sim 6\text{s}$ del LLM mediante estrategias de caché o destilación, y liberar la Master Table y scripts como benchmarks públicos.

Agradecimientos: Dios, Grupo Investivacion IMS FUP, Camilo Ordoñez

Referencias

- [1] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A.N., Kaiser, L., Polosukhin, I.: Attention is all you need. In: Advances in Neural Information Processing Systems 30 (NeurIPS), pp. 5998–6008 (2017)
- [2] Sun, F., Liu, J., Wu, J., Pei, C., Lin, X., Ou, W., Jiang, P.: BERT4Rec: Sequential recommendation with bidirectional encoder representations from transformer. In: ACM International Conference on Information and Knowledge Management (CIKM), pp. 1441–1450 (2019)
- [3] Kang, W.C., McAuley, J.: Self-attentive sequential recommendation. In: IEEE International Conference on Data Mining (ICDM), pp. 197–206 (2018)
- [4] Bertin-Mahieux, T., Ellis, D.P.W., Whitman, B., Lamere, P.: The million song dataset. In: Proceedings of the 12th International Society for Music Information Retrieval Conference (ISMIR), pp. 591–596 (2011)
- [5] Tikat, A., Sordo, M., Celma, O., Serra, X.: The WASABI dataset: Cultural, lyrics and audio analysis metadata about 2 million popular commercially released songs. In: Proceedings of the 22nd International Society for Music Information Retrieval Conference (ISMIR), pp. 862–869 (2021)
- [6] Moura, L., Fontelles, E., Sampaio, V., França, M.: Music Dataset: Lyrics and Metadata from 1950 to 2019. Mendeley Data, V2. doi:10.17632/3t9vbwxgr5.2 (2020)
- [7] Choi, K., Doh, S., Nam, J.: TalkPlayData 2: An agentic synthetic data pipeline for multimodal conversational music recommendation. arXiv preprint arXiv:2509.09685 (2025)
- [8] Armbrust, M., Buragohain, P., Xin, R., et al.: Delta Lake: High-performance ACID table storage over cloud object stores. Proceedings of the VLDB Endowment 13(12), 3411–3424 (2020)
- [9] Christakopoulou, K., Radlinski, F., Hofmann, K.: Towards conversational recommender systems. In: Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, pp. 815–824 (2016)
- [10] Gao, C., Lei, W., He, X., de Rijke, M., Chua, T.S.: Advances and challenges in conversational recommender systems. AI Open 2, 100–126 (2021)



Gracias

¿Preguntas?

John Kennedy Landazuri Sandoval

john.landazuri@estudiante.fup.edu.co

ORCID: 0009-0001-2345-6789

