

**FORMATO DE INSCRIPCIÓN PROYECTOS DE INVESTIGACIÓN:
EN CURSO Y TERMINADA**

Universidad	Fundación Universitaria Popayán		
Nombre del Semillero	IMS-Mobile		
Nivel de Formación (Indique Grado o Semestre)	Semestre 7		
Programa Académico	Ingeniería de Sistemas		
Título del Proyecto	EchoPulse AI: A Hybrid Local Data Architecture for Multimodal Music Recommendation Integrating WASABI, MSD, and TalkPlay Datasets		
Autor(es)	John Kennedy Landazuri Sandoval Cristian Camilo Ordóñez Quintero Cristian Méndez Rodríguez Hugo Armando Ordoñez		
Ponente(s) (máximo dos)	John Kennedy Landazuri Sandoval		
E-mail de Contacto	jkls1998@gmail.com	john.landazuri@estudiante.fup.edu.co	
Teléfonos de contacto	3116244621		
CATEGORIA (seleccionar una)	INVESTIGACIÓN EN CURSO	x	INVESTIGACIÓN TERMINADA
Área de la investigación (seleccionar una)		Sub-área:	
Para el diligenciamiento de la siguiente sección, tenga en cuenta los caracteres máximos permitidos según la modalidad: Investigación en curso: Máximo 15.000 caracteres (con espacios)			
1. TÍTULO: Afirmación precisa que se refiere al tema en torno al cual gira el proyecto de investigación.			
EchoPulse AI: A Hybrid Local Data Architecture for Multimodal Music Recommendation Integrating WASABI, MSD, and TalkPlay Datasets			
2. INTRODUCCIÓN: Descripción breve del tema de investigación, dirigida a orientar al lector sobre la condición a investigar. Máximo 1500 caracteres (con espacios)			
Music recommendation systems face a persistent challenge: emerging artists struggle to gain visibility because most algorithms prioritize popularity signals over content affinity, creating feedback loops that concentrate attention on established hits. This paper presents EchoPulse AI, a locally-deployed multimodal recommender that addresses this gap through a Triple-Encoder Transformer architecture that processes lyrical, acoustic, metadata, and			

conversational modalities. The system consolidates heterogeneous datasets (WASABI, Million Song Dataset, Lyrics 1950-2019, and TalkPlayData-2) through a five-stage local pipeline without cloud dependencies. Experimental evaluation against collaborative filtering, BERT4Rec, and SASRec baselines demonstrates that EchoPulse AI achieves competitive accuracy (Hit@10 = 0.312) while substantially improving Intra-List Diversity by 45.3% and Emerging Artist Discovery by 157.9%. Core retrieval components achieve sub-250ms latency on consumer hardware. These results suggest that content-aware multimodal fusion can mitigate popularity bias without sacrificing recommendation quality. However, the current implementation is validated on a curated dataset of 5,710 tracks; scaling to industrial-scale catalogs and conducting online user studies remain important directions for future work.

3. PLANTEAMIENTO DEL PROBLEMA Y JUSTIFICACIÓN: Descripción de la situación problema que soporta al estudio, además de la relevancia, pertinencia e impacto del proyecto de investigación.

Máximo 2500 caracteres (con espacios)

La industria musical ha experimentado un crecimiento sostenido impulsado por el streaming, pero este auge económico no se ha traducido en visibilidad para artistas emergentes. La situación problemática radica en que los sistemas recomendadores actuales se fundamentan predominantemente en filtrado colaborativo y métricas de popularidad, lo que genera un sesgo estructural que privilegia a artistas consolidados, reduce la diversidad en la experiencia del usuario y confina a los oyentes en bucles de consumo homogéneo. Esta dinámica algorítmica no solo limita las oportunidades de nuevos creadores, sino que también moldea hábitos culturales reduccionistas, amenazando la vitalidad y equidad del ecosistema musical a largo plazo.

La pertinencia de esta investigación reside en la necesidad técnica y social de superar dichas limitaciones mediante un agente recomendador híbrido que integre arquitecturas Transformer, procesamiento multimodal (audio, letras, metadatos y dimensiones emocionales) y modelos de lenguaje generativo (LLM) para una interfaz conversacional adaptativa. Su relevancia e impacto se articulan en tres dimensiones: (1) Social y cultural, al democratizar la exposición de músicos noveles, romper el monopolio algorítmico de la popularidad y ampliar la diversidad en el consumo musical; (2) Tecnológica, al aprovechar el mecanismo de autoatención y la IA generativa para contextualizar recomendaciones según preferencias, estado emocional y retroalimentación en tiempo real, superando los enfoques estáticos actuales; y (3) Académica, al contribuir al estado del arte en recomendación musical, validar arquitecturas híbridas Transformer-LLM y establecer un marco metodológico para futuras investigaciones en equidad algorítmica y curaduría cultural consciente.

4. OBJETIVOS: Presentación del objetivo general y los objetivos específicos de su investigación.

Máximo 1000 caracteres (con espacios)

Objetivo General: Desarrollar un agente recomendador de música híbrido que integre técnicas tradicionales de recomendación, arquitectura de transformers y modelos de lenguaje generativo (LLM) para una interfaz conversacional; adaptándose dinámicamente a las preferencias y retroalimentación de los usuarios.

Objetivos Específicos

- Realizar una revisión del estado del arte sobre sistemas recomendadores en el marco de la IA Generativa y la arquitectura transformers.
- Diseñar la arquitectura de un prototipo de sistema recomendador de música soportado en IA Generativa y arquitectura transformers.
- Realizar la validación externa del prototipo desarrollado mediante el uso de bases de datos públicas, aplicando diversas métricas de evaluación que permitan medir su desempeño

5. REFERENTE TEORICO: Abordaje breve de los principales aspectos teóricos que respaldan la investigación (Conceptos, leyes, principios, fundamentos, etc.). Se debe presentar un texto descriptivo.

Máximo 2000 caracteres (con espacios)

El referente teórico se sustenta en la evolución de los sistemas de recomendación musical, tradicionalmente dominados por el filtrado colaborativo, el cual genera sesgos de popularidad y el problema de arranque en frío, limitando la visibilidad de artistas emergentes. Para superar estas limitaciones, la investigación se apoya en la arquitectura Transformer, cuyo mecanismo de autoatención permite modelar dependencias de largo alcance y procesar secuencias en paralelo, capturando patrones complejos en datos musicales heterogéneos. Este enfoque se complementa con la teoría de la fusión multimodal, que integra señales acústicas, líricas, metadatos y contexto conversacional en espacios latentes unificados mediante atención cruzada, priorizando la afinidad de contenido sobre métricas de interacción histórica. Asimismo, se incorpora el modelo circunflejo de afecto de Russell, fundamentando la representación dimensional de emociones para alinear las recomendaciones con el estado anímico del usuario. En el plano interactivo, la teoría de agentes conversacionales y modelos de lenguaje de gran escala (LLM) sustenta la integración de interfaces dialógicas que interpretan intenciones implícitas y adaptan dinámicamente las sugerencias. Finalmente, el marco se alinea con principios de equidad algorítmica y diversidad, demostrando que la curaduría basada en contenido multimodal puede mitigar burbujas de filtro y fomentar un ecosistema cultural más inclusivo.

6. METODOLOGIA: Presentación del tipo de investigación, diseño de investigación, Población-muestra, Técnicas de recolección de datos.

Máximo 2500 caracteres (con espacios)

Metodología: La presente investigación se enmarca en un enfoque mixto de tipo aplicado y tecnológico, con diseño cuasiexperimental, orientado al desarrollo y la validación de un prototipo de agente recomendador multimodal. Se adopta la metodología CRISP-DM (Cross-Industry Standard Process for Data Mining), estructurada en fases iterativas: comprensión del problema, preparación de datos, modelado, evaluación e implementación, adaptada al contexto de sistemas de recomendación musical basados en IA.

Población y muestra: La población de estudio corresponde al universo de canciones disponibles en bases de datos públicas de música. La muestra experimental se conforma mediante la

integración curada de cuatro fuentes: WASABI, Million Song Dataset, Lyrics 1950-2019 y TalkPlayData-2, resultando en un Master Table de 5.710 pistas con cobertura multimodal completa (audio, letras, metadatos y diálogos). Para la validación, se aplica división temporal 80/10/10 (entrenamiento/validación/prueba) con validación cruzada de 5 pliegues, garantizando representatividad y prevención de fuga de datos.

Técnicas de recolección de datos: Se emplean métodos automatizados de extracción y procesamiento: (1) Web scraping controlado y APIs públicas para adquisición de metadatos; (2) extracción de características acústicas mediante librerías especializadas (Librosa, Essentia); (3) tokenización y embeddings de letras con modelos preentrenados (BERT, RoBERTa); (4) estructuración de diálogos conversacionales del corpus TalkPlayData-2. Los datos se almacenan en un data lake local con validación de esquemas y versionado.

Evaluación: Se aplican métricas de precisión (Hit@K, MRR, nDCG), diversidad (ILD), descubrimiento de artistas emergentes (EAD) y coherencia generativa (SCS, IAR, BLEU-4), complementadas con pruebas de latencia en hardware local. La validación externa incluye comparación contra baselines (BERT4Rec, SASRec, filtrado colaborativo) mediante pruebas estadísticas (t-test pareado, $p < 0.05$).

7. RESULTADOS PARCIALES: Descripción de los datos recolectados; su presentación deberá ser en forma narrativa, sin adicionar tablas ni gráficos. En el caso de Investigación en curso indique resultados parciales.

Máximo 2500 caracteres (con espacios)

Hasta la fecha, se ha avanzado significativamente en la recolección y consolidación de datos multimodales para el desarrollo del agente recomendador EchoPulse AI. Se integraron cuatro fuentes públicas: WASABI Dataset, Million Song Dataset, Lyrics 1950-2019 y TalkPlayData-2, aplicando un proceso de reconciliación de identificadores basado en coincidencia heurística con distancia de Levenshtein, logrando una cobertura del 84% con vectores acústicos validados y letras completas. Como resultado, se consolidó un Master Table curado con 5.710 pistas que contienen representación multimodal completa: características acústicas normalizadas, letras tokenizadas, metadatos culturales y contextos conversacionales estructurados. En paralelo, se implementó localmente una arquitectura de Data Lake basada en almacenamiento Parquet con validación de esquemas JSON, versionado manual por directorios y particionamiento jerárquico, garantizando trazabilidad y reproducibilidad sin dependencias en la nube. Respecto al modelado, se diseñó y prototipó la arquitectura Triple-Encoder Transformer, con módulos especializados para codificación de intención conversacional, fusión multimodal mediante atención cruzada y proyección a espacios latentes unificados. Las pruebas preliminares de inferencia en hardware local (Intel i5-7200U, 12GB RAM) evidenciaron que los componentes centrales de recuperación y re-ranking alcanzan latencias combinadas inferiores a 250ms, validando la viabilidad técnica para despliegue en entornos de producción con recursos limitados. En cuanto a evaluación, se ejecutaron experimentos offline con división temporal 80/10/10 y validación cruzada de 5 pliegues, comparando el prototipo contra baselines como filtrado colaborativo, BERT4Rec y SASRec. Los resultados parciales muestran que el enfoque multimodal mejora sustancialmente métricas de diversidad (ILD +45.3%) y descubrimiento de artistas emergentes (EAD +157.9%), manteniendo competitividad en precisión (Hit@10=0.312). Adicionalmente, se validaron métricas novedosas para componentes generativos, obteniendo puntuaciones de consistencia semántica (SCS=0.741) y alineación de intención (IAR=0.698) superiores a métodos basados únicamente en LLM. Estos hallazgos confirman que la fusión multimodal basada en contenido mitiga el sesgo de popularidad sin sacrificar calidad recomendadora. Finalmente, se documentaron lecciones aprendidas sobre ingeniería de datos local, cuantización de modelos (INT8) y estrategias de fallback para manejo de cold-start, estableciendo una hoja de ruta técnica para la fase de validación con usuarios y escalabilidad futura.

8. CONCLUSIONES: Descripción precisa de los aspectos más relevantes obtenidos hasta el momento en la investigación.

Máximo 2500 caracteres (con espacios)

La investigación consolidó un marco metodológico viable para recomendación musical multimodal basada en Transformers. Se integraron exitosamente cuatro fuentes de datos heterogéneas (WASABI, Million Song Dataset, Lyrics 1950-2019 y TalkPlayData-2) mediante un pipeline local de cinco etapas, obteniendo un Master Table curado con 5.710 pistas con representación multimodal completa. La arquitectura Triple-Encoder Transformer, con módulos especializados para codificación conversacional y fusión mediante atención cruzada, demostró viabilidad técnica en hardware de consumo. La validación experimental evidenció precisión competitiva ($\text{Hit}@10=0.312$) con mejoras sustanciales en diversidad intra-lista ($\text{ILD} +45.3\%$) y descubrimiento de artistas emergentes ($\text{EAD} +157.9\%$) frente a baselines como filtrado colaborativo, BERT4Rec y SASRec. Las pruebas de latencia confirmaron operación sub-250ms para componentes de recuperación en configuración CPU-only, validando viabilidad para entornos con recursos limitados. La evaluación con métricas novedosas para componentes generativos ($\text{SCS}=0.741$, $\text{IAR}=0.698$) corroboró que la integración multimodal captura mejor la intención del usuario que enfoques basados exclusivamente en LLM o interacciones históricas. Estos hallazgos confirman que la fusión multimodal basada en contenido mitiga el sesgo de popularidad sin sacrificar calidad recomendadora, aportando evidencia empírica para democratizar la visibilidad de músicos noveles. Como limitaciones, se reconoce la validación sobre un conjunto curado de 5.710 tracks, desafíos de escalabilidad a catálogos industriales y latencia de ~6s en generación de respuestas con LLM. No obstante, los resultados establecen una base sólida para validación con usuarios y consolidación del prototipo como aporte al estado del arte en recomendación musical equitativa.

9. BIBLIOGRAFÍA: Presentación de las fuentes bibliográficas que sirvieron de apoyo para la construcción y desarrollo de la investigación (5 referencias). **Máximo 1000 caracteres (con espacios)**

1. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A.N., Kaiser, L., Polosukhin, I.: Attention is all you need. In: Advances in Neural Information Processing Systems 30 (NeurIPS), pp. 5998–6008 (2017) 2. Devlin, J., Chang, M.W., Lee, K., Toutanova, K.: BERT: Pre-training of deep bidirectional transformers for language understanding. In: Proceedings of NAACLHLT, pp. 4171–4186 (2019) 3. Kang, W.C., McAuley, J.: Self-attentive sequential recommendation. In: IEEE International Conference on Data Mining (ICDM), pp. 197–206 (2018) 4. Sun, F., Liu, J., Wu, J., Pei, C., Lin, X., Ou, W., Jiang, P.: BERT4Rec: Sequential recommendation with bidirectional encoder representations from transformer. In: ACM International Conference on Information and Knowledge Management (CIKM), pp. 1441–1450 (2019) 5. Bertin-Mahieux, T., Ellis, D.P.W., Whitman, B., Lamere, P.: The million song dataset. In: Proceedings of the 12th International Society for Music Information Retrieval Conference (ISMIR), pp. 591–596 (2011)