

La Arquitectura de Datos Híbrida: Justificando la Fusión de WASABI y MSD para un Recomendador Musical Multimodal

Evaluación de la Integridad Multimodal y Riqueza de Metadatos

La construcción de un agente recomendador de música verdaderamente multimodal, especialmente uno basado en arquitecturas de tipo Transformer, depende críticamente de la disponibilidad de datos que integren de manera coherente y alineada múltiples modalidades: texto (letras), audio (características acústicas) y metadatos estructurados (género, artista, año, popularidad). El análisis comparativo de los conjuntos de datos existentes revela una disparidad significativa en su capacidad para satisfacer este requisito fundamental. Las fuentes pueden clasificarse en función de su integridad multimodal, donde algunas ofrecen riqueza en una modalidad específica mientras carecen de otras, lo que implica la necesidad de estrategias de fusión para alcanzar el objetivo propuesto.

El Million Song Dataset (MSD) es quizás el recurso más citado y utilizado en la investigación de recuperación de información musical (MIR) [34](#) [71](#). Su principal fortaleza radica en la escala y la profundidad de sus características acústicas. Se describe como una colección libre de audio features y metadatos para un millón de temas populares contemporáneos [5](#) [9](#) [84](#). Proporciona un conjunto robusto de características de baja nivel, como tonalidad, clave, energía, tempo y armónicos, que son indispensables para cualquier modelo musical [53](#). Sin embargo, la característica más definitoria del MSD es también su mayor limitación para este proyecto específico: su ausencia casi total de datos de letras. Esta falta de modalidad textual lo descarta como una fuente única viable para un sistema diseñado para ser intrínsecamente multimodal desde su concepción. Aunque se han realizado intentos de mejorar sus anotaciones de género a partir de bases de datos externas [89](#), los metadatos disponibles en su núcleo tienden a ser básicos, centrados principalmente en la información derivada de los perfiles de escucha del usuario y atributos fundamentales de la canción [93](#). Por lo tanto, aunque el MSD sigue siendo un

estándar de facto para la prueba de escalabilidad y rendimiento de algoritmos acústicos [7](#) [85](#), su incapacidad para proporcionar letras le impide cumplir con el criterio básico de integridad multimodal.

En contraste, The WASABI Dataset emerge como un candidato mucho más prometedor y completo. Desarrollado como una base de conocimiento, WASABI contiene metadatos de corte cultural, líricas y análisis acústico para más de dos millones de canciones comerciales [3](#) [4](#) [21](#). Esta naturaleza integrada lo posiciona como una solución nativa para el desafío de la multimodalidad. La plataforma ofrece una riqueza de metadatos que va más allá de los simples atributos de una pista, incorporando contexto cultural que puede ser invaluable para entender las tendencias y afinidades musicales de los usuarios [2](#). Además, su cobertura temporal, que abarca desde 1922 hasta 2022, permite un análisis longitudinal profundo y la construcción de modelos capaces de capturar la evolución de la música a lo largo del tiempo [10](#). La integración de estas tres modalidades —texto, acústica y metadatos culturales— dentro de una única base de conocimiento lo convierte en el pilar central más sólido para la arquitectura de datos propuesta.

Un tercer conjunto de datos relevante es el denominado "Music Dataset: 1950 to 2019", disponible en plataformas como Kaggle [1](#) [29](#) [54](#). Este recurso se presenta como una compilación que integra letras con metadatos descriptivos para canciones entre 1950 y 2019 [1](#) [69](#). Su principal ventaja reside en esta combinación de texto y metadatos semánticos. Los metadatos asociados a las letras no son meramente etiquetas, sino que describen conceptos abstractos como "tristeza", "baile", así como características acústicas subjetivas como "volumen" y "acústica" [1](#) [29](#). Esto representa un valioso recurso para modelar la dimensión emocional y temática de la música. No obstante, este conjunto de datos presenta debilidades importantes. Las fuentes no especifican con claridad el origen ni la calidad de estos metadatos descriptivos; no se detalla si fueron extraídos automáticamente mediante procesamiento de lenguaje natural o anotados manualmente, lo cual introduce un riesgo considerable en cuanto a su consistencia y fiabilidad. Además, aunque menciona características acústicas, no hay evidencia directa de que contenga las características de baja nivel (como MFCCs o BPM exactos) que son fundamentales para el análisis musical profundo y que se encuentran de manera preeminentemente en el MSD. Por lo tanto, este dataset es una fuente potencialmente muy valiosa para la modalidad textual y de metadatos descriptivos, pero su dependencia de un origen secundario y la incertidumbre sobre la calidad de sus datos lo convierten en un recurso de alto riesgo para ser la única fuente de verdad.

A continuación se presenta una tabla comparativa que resume las características de integridad multimodal de los conjuntos de datos analizados.

Característica	Million Song Dataset (MSD)	The WASABI Dataset	Music Dataset: 1950-2019
Modalidad de Letras	Ausente 5	Presente (líricas) 3	Presente 1
Modalidad Acústica	Presente (características de baja nivel) 53	Presente (análisis acústico) 4	Presente (características acústicas descriptivas) 1
Modalidad Metadatos	Presente (básicos: ID, artista, título) 93	Presente (ricos: culturales, de álbum, de artista) 2	Presente (descriptivos: tristeza, baile, etc.) 29
Integridad Multimodal	Baja (solo acústica y metadatos básicos)	Alta (integración nativa de las tres modalidades)	Media-Alta (integración de texto y metadatos descriptivos, pero con incertidumbre en la calidad y la presencia de acústica de baja nivel)
Fuente Original	The Echo Nest Taste Profiles 93	Proyecto académico (Tikat et al.) 21	Compilación de diversas fuentes 1

En conclusión, ningún conjunto de datos único satisface de manera óptima todos los requisitos de integridad multimodal. El MSD es insuficiente por su falta de letras, mientras que el dataset de Kaggle presenta incertidumbres sobre la calidad de sus datos. The WASABI Dataset destaca como la opción más completa y equilibrada debido a su estructura nativamente multimodal y su riqueza en metadatos contextuales. Por lo tanto, la estrategia más viable para construir un sistema robusto no es la elección de una sola fuente, sino la implementación de un esquema de fusión que combine las fortalezas de múltiples conjuntos de datos, utilizando WASABI como núcleo y complementándolo con datos adicionales.

Análisis de Cobertura Temporal, Representatividad de Género y Sesgo de Popularidad

Más allá de la integridad multimodal, la idoneidad de un conjunto de datos para entrenar un sistema de recomendación depende de su capacidad para reflejar la diversidad del panorama musical global, tanto en términos de época como de género. Un dataset con una cobertura temporal limitada o un sesgo pronunciado hacia géneros o artistas populares puede conducir a modelos que no generalizan bien y que perpetúan desigualdades existentes en la industria musical. El análisis de estas dimensiones revela patrones significativos en los conjuntos de datos disponibles que deben ser cuidadosamente considerados en la selección de la fuente de datos.

The WASABI Dataset demuestra una cobertura temporal excepcionalmente amplia, abarcando grabaciones comerciales desde 1922 hasta 2022 [10](#) . Esta ventana de más de un siglo permite un análisis longitudinal sin precedentes, facilitando la creación de modelos que puedan capturar la evolución de las características musicales, temáticas y estilísticas a lo largo del tiempo. Por ejemplo, se podría investigar cómo ha cambiado la simplicidad de las letras en la música pop a lo largo de las décadas [30](#) o cómo las características emocionales de la música han variado [90](#) . Esta extensión cronológica es una ventaja competitiva significativa sobre otras fuentes. En cuanto a la representatividad de género, WASABI contiene metadatos de corte cultural, lo que sugiere una posible inclusión de una variedad de géneros más allá de la música pop dominante [77](#) . Sin embargo, dado que se describe como una base de conocimiento de "canciones comerciales", existe una preocupación inherente sobre un posible sesgo hacia artistas y géneros que han alcanzado un cierto nivel de popularidad o distribución comercial, lo que podría afectar la inclusión de géneros menos mainstream o de artistas independientes.

El Million Song Dataset (MSD), por otro lado, se centra explícitamente en "música popular contemporánea" [5](#) [9](#) . Si bien esto le confiere una gran cantidad de datos de géneros dominantes en el mercado moderno, también establece un sesgo claro. Su foco en la "contemporaneidad" limita su utilidad para estudiar la historia de la música o para crear modelos que recomienden obras clásicas o de nichos históricos. La representatividad de géneros en el MSD depende enteramente de qué se considera "popular" en el período cubierto, lo que probablemente favorezca a géneros occidentales y angloparlantes. Este sesgo hacia la popularidad es una consecuencia directa de su origen en los perfiles de escucha del The Echo Nest [93](#) , que reflejan las preferencias de un público digital y, por ende, de los artistas más escuchados. Este problema se relaciona directamente con el desafío del "inicio en frío" para nuevos contenidos, donde los elementos menos populares reciben menos exposición y, por lo tanto, menos datos de interacción [58](#) .

El "Music Dataset: 1950 to 2019" presenta una cobertura temporal similar a la de WASABI, abarcando seis décadas de música estadounidense [79](#) [81](#) . Esta amplitud permite estudios longitudinales sobre cambios culturales y lingüísticos a través de las letras de las canciones. Sin embargo, su alcance geográfico parece estar limitado a las listas de éxitos de Estados Unidos, lo que reduce su representatividad global de la música. La representatividad de género también podría verse afectada por esta concentración en un mercado específico. Al igual que el MSD, su enfoque en "las 100 mejores canciones de cada año" [79](#) introduce un fuerte sesgo hacia la popularidad, haciendo que sea una fuente menos adecuada para el objetivo de posicionar a músicos noveles.

Para ilustrar la magnitud de estos sesgos, se pueden realizar análisis exploratorios de los datos. Por ejemplo, se puede calcular la distribución de popularidad de las pistas en cada dataset. Una visualización común sería un histograma que muestre la frecuencia de pistas agrupadas por cuartiles de popularidad. Se esperaría observar que una gran mayoría de las pistas en el MSD y el dataset de Kaggle pertenecen al cuartil superior de popularidad, mientras que el WASABI, al incluir datos de 1922, podría mostrar una distribución más dispersa, aunque aún con un sesgo hacia lo comercial. De manera similar, un diagrama de barras que muestre la frecuencia de géneros en cada dataset revelaría diferencias notables. El MSD probablemente mostraría una dominancia de géneros como Pop, Rock e Hip-Hop, mientras que el WASABI, al contar con metadatos culturales, podría ofrecer una visión más matizada de la diversidad musical.

La siguiente tabla resume las características de cobertura y representatividad de los datasets analizados:

Característica	Million Song Dataset (MSD)	The WASABI Dataset	Music Dataset: 1950-2019
Cobertura Temporal	Contemporáneo (no especificado, pero enfocado en música popular actual) 5	Amplia (1922-2022) 10	Extensa (1950-2019) 1
Representatividad Geográfica	Global, pero sesgada por la popularidad 71	Global, enfocado en canciones comerciales 3	Limitada a EE. UU. (listas de éxito) 79
Sesgo de Popularidad	Alto (basado en perfiles de escucha de The Echo Nest) 93	Moderado-Alto ("comercial songs") 3	Muy Alto ("Top 100 Songs of the Year") 79

Estos análisis indican que, si bien todos los datasets tienen valor, ninguno es completamente neutro. El WASABI ofrece la mejor combinación de amplia cobertura temporal y riqueza de metadatos, aunque con un sesgo inherente hacia lo comercial. El dataset de Kaggle es útil para análisis longitudinales en un contexto cultural específico pero su sesgo de popularidad es extremo. El MSD es una referencia acústica a gran escala pero su foco en la contemporaneidad y la popularidad lo limita en términos de diversidad histórica y de género. Por lo tanto, la estrategia de datos debe reconocer estos sesgos y, si es necesario, proponer mecanismos en el propio modelo para mitigarlos, como la ponderación inversa de la popularidad durante el entrenamiento o la implementación de políticas de exploración para dar voz a contenido menos popular pero contextualmente relevante.

Estrategias de Fusión y Esquemas de Integración de Datos

La selección de una única fuente de datos multimodal completa resulta ser una tarea compleja, ya que cada conjunto de datos existente presenta fortalezas y debilidades. La solución más robusta y estratégica consiste en adoptar una arquitectura de datos híbrida que combine las fortalezas de múltiples fuentes. Esta aproximación, sin embargo, introduce una serie de desafíos técnicos significativos relacionados con la fusión de datos heterogéneos, la gestión de identificadores únicos y la resolución de inconsistencias entre fuentes. La correcta implementación de un pipeline de procesamiento es crucial para transformar datos brutos en un recurso de alta calidad, listo para alimentar un modelo Transformer avanzado.

La estrategia de fusión más lógica para este proyecto se basaría en utilizar The WASABI Dataset como el núcleo central. Su integridad multimodal nativa y su riqueza en metadatos culturales lo convierten en un excelente punto de partida [3](#) [77](#). Sobre este núcleo, se podrían realizar dos tipos de enriquecimiento. Primero, se podrían añadir las características acústicas de baja nivel del Million Song Dataset (MSD), como tempero, tonalidad y energía, que son fundamentales para el análisis musical profundo [53](#). Segundo, se podrían incorporar los metadatos descriptivos (como valencia, activación o temas extraídos de las letras) del "Music Dataset: 1950 to 2019", siempre y cuando se pueda validar su calidad y origen [1](#) [29](#). Esta estrategia híbrida permitiría construir un conjunto de datos final con una representación de la música mucho más completa y matizada.

El primer y más importante desafío técnico en esta fusión es la creación de un identificador único y universal para cada pista musical. Los conjuntos de datos utilizan sistemas de identificación distintos y no siempre compatibles. Por ejemplo, el MSD utiliza IDs de The Echo Nest [93](#), mientras que WASABI probablemente tiene su propio sistema de identificación interna. El proceso de fusión requerirá un mapeo cuidadoso entre estos identificadores. Dado que un mapeo perfecto y automático es improbable, se deberá depender de claves de combinación heurísticas, como la tupla (nombre de la canción, nombre del artista, año de lanzamiento). Este enfoque, aunque efectivo, introduce un grado de error inherente, ya que pueden existir canciones homónimas o errores de transcripción en los metadatos. La limpieza y normalización de los nombres de canciones y artistas antes de intentar el mapeo será un paso previo indispensable.

Una vez resuelto el problema de la identificación, surge el desafío de la gestión de la inconsistencia. Es altamente probable que las características de la misma canción varíen

ligeramente entre diferentes fuentes. Por ejemplo, el BPM calculado para una canción en el MSD podría ser ligeramente diferente al proporcionado por WASABI. Del mismo modo, los metadatos descriptivos del dataset de Kaggle podrían entrar en conflicto con las anotaciones culturales de WASABI. El pipeline de procesamiento debe incluir una lógica explícita para manejar estas discrepancias. Las estrategias podrían incluir: 1) Priorizar una fuente sobre otra (por ejemplo, dar prioridad a las características acústicas del MSD si se considera su método de extracción más preciso); 2) Calcular un valor promedio o ponderado para características numéricas; o 3) Crear campos separados para cada fuente de datos, permitiendo al modelo Transformer aprender a ponderar la confianza en cada fuente. La transparencia en este proceso es vital para la reproducibilidad del experimento.

Para gestionar la complejidad de esta arquitectura de datos híbrida, la adopción de un paradigma de Data Lakehouse es la solución más adecuada. Un Data Lakehouse combina la flexibilidad y la escalabilidad de un data lake con las capacidades transaccionales y de gestión de metadatos de un data warehouse ²⁵. Implementar este flujo de trabajo sobre una plataforma como Delta Lake, Apache Iceberg o Apache Hudi permite almacenar todos los datos —crudos, fusionados e intermedios— en un único repositorio centralizado ²⁵. Estos formatos de tabla modernos ofrecen funcionalidades cruciales como transacciones ACID sobre datos en bruto, evolución de esquemas y "viaje en el tiempo" (time travel), que permite acceder a versiones pasadas de los datos ²⁵. Esto asegura la trazabilidad completa del proceso de fusión, desde los datos originales de cada fuente hasta el conjunto de datos final preparado para el entrenamiento del modelo. La automatización de este pipeline de ETL/ELT es esencial para mantener un ciclo de desarrollo rápido y fiable, permitiendo a los científicos de datos iterar sobre sus ideas y validar nuevas características de forma eficiente.

En resumen, la estrategia de fusión de datos es un componente crítico del diseño del sistema. Requiere un enfoque sistemático que aborde los problemas de identificación, inconsistencia y calidad. La elección de una arquitectura de Data Lakehouse no es solo una decisión técnica, sino una decisión estratégica que garantiza la escalabilidad, la fiabilidad y la reproducibilidad del proyecto a largo plazo.

Idoneidad para el Posicionamiento de Músicos Novenos

Uno de los objetivos declarados del anteproyecto es no solo construir un sistema de recomendación preciso, sino también desarrollar un agente que contribuya al

posicionamiento de músicos noveles. Este objetivo introduce un desafío teórico y práctico significativo, conocido como el problema del "inicio en frío" ⁵⁸. Los datasets de música existentes, por su propia naturaleza y origen, presentan un sesgo pronunciado hacia artistas y canciones populares, lo que crea un obstáculo formidable para cualquier modelo entrenado exclusivamente con estos datos. Evaluar la idoneidad de las fuentes de datos para este propósito específico es, por lo tanto, una tarea de suma importancia.

El problema del "inicio en frío" se manifiesta de dos formas principales: self-unfairness, donde los nuevos videos o canciones carecen de exposición inicial, y cross-unfairness, donde las nuevas entradas de alta calidad no reciben la oportunidad de competir con el contenido establecido ⁵⁸. Los conjuntos de datos disponibles reflejan y a menudo exacerban este problema. El Million Song Dataset, con su origen en los perfiles de escucha del usuario de The Echo Nest, está intrínsecamente sesgado hacia la popularidad ⁹³. Solo las canciones que ya habían acumulado suficientes interacciones para ser incluidas en el dataset están representadas, dejando fuera a la vasta mayoría de los artistas independientes y emergentes.

De manera similar, The WASABI Dataset se describe explícitamente como una base de conocimiento de "música comercial" ³ ⁴. Si bien su escala es mayor que la del MSD, el término "comercial" sugiere una preferencia por artistas y sellos discográficos que han logrado un cierto nivel de distribución masiva. Aunque su amplia cobertura temporal desde 1922 podría incluir artistas de épocas pasadas que hoy son considerados "noveles" en ciertos nichos, es poco probable que capture dinámicamente a los nuevos talentos que surgen diariamente en plataformas digitales como Bandcamp, SoundCloud o incluso TikTok. El dataset "Music Dataset: 1950 to 2019", al basarse en las listas de éxitos de Billboard, presenta el sesgo de popularidad más extremo de todos, ya que solo incluye las canciones que alcanzaron el número uno en las listas de ventas ⁷⁹.

Para abordar esta limitación, es imperativo realizar un análisis cuantitativo de la representación de artistas noveles en cada dataset. Esto implicaría definir un criterio para "novo" (por ejemplo, artistas con menos de 100,000 oyentes mensuales en Spotify, o aquellos que no aparecen en listas de popularidad tradicionales) y luego calcular su proporción en cada conjunto de datos. Es altamente probable que esta proporción sea extremadamente baja o nula en el MSD y WASABI. Esta constatación tiene implicaciones directas para la arquitectura del modelo. Un modelo puramente basado en colaboración o en similitudes de contenido aprendidas a partir de datos sesgados tenderá a reforzar la popularidad existente, creando un bucle virtuoso para los artistas establecidos y un bucle vicioso para los noveles.

Por lo tanto, el anteproyecto debe ir más allá de la simple selección de datos y proponer soluciones técnicas para mitigar este sesgo. Una primera línea de defensa es la recolección de datos adicionales de fuentes alternativas. Plataformas especializadas como SoundCloud, Bandcamp o evenToot podrían ser explotadas para obtener datos sobre artistas emergentes. Esto requeriría un esfuerzo de ingeniería de características para extraer características acústicas y analizar letras de estas nuevas fuentes, y luego integrarlas en el Data Lakehouse. Una segunda estrategia, que se implementa en el propio modelo, es la introducción de mecanismos de exploración. En lugar de siempre recomendar la canción con la puntuación de predicción más alta, el sistema podría utilizar una política epsilon-greedy, donde con una pequeña probabilidad epsilon, en lugar de explotar (seleccionar la mejor opción conocida), el sistema explora (elige aleatoriamente una canción de un conjunto de candidatos, posiblemente filtrado por reciente lanzamiento o por ser de un nuevo artista). Esto daría una oportunidad a nuevas entradas para ser descubiertas por los usuarios.

Además, el modelo Transformer podría ser diseñado específicamente para abordar este problema. En lugar de simplemente predecir la probabilidad de escucha, el modelo podría tener una tarea auxiliar de clasificación de popularidad o de detección de "novedad". Esto obligaría al modelo a aprender representaciones de artistas y canciones que capturen no solo su contenido (letras, acústica) y popularidad pasada, sino también sus características intrínsecas que podrían indicar potencial de futuro éxito. La estrategia de optimización multi-tarea, donde el objetivo de entrenamiento es una combinación ponderada de varias funciones de pérdida, podría ser particularmente útil aquí ⁶⁰. Por ejemplo, el modelo podría ser entrenado simultáneamente para predecir la próxima escucha, para clasificar correctamente si un usuario abandonará el servicio, o para predecir la categoría o SKU de un producto .

En conclusión, aunque los datasets existentes no están diseñados para el posicionamiento de músicos noveles, el anteproyecto puede abordar este desafío de manera proactiva. El informe de investigación debe dedicar una sección crítica a este problema, presentando los hallazgos sobre la falta de representación de artistas novenos en los datasets actuales y proponiendo una combinación de recolección de datos externos y técnicas de modelado innovadoras como parte integral del plan de proyecto.

Implicaciones Arquitectónicas y Justificación de la Selección de Datos

La selección de la fuente de datos no es una decisión aislada, sino que tiene profundas implicaciones en la arquitectura del modelo Transformer y en la metodología de modelado en su conjunto. La naturaleza de los datos disponibles dicta la forma en que se representan las entradas, la estrategia de fusión multimodal a implementar y, en última instancia, el potencial del sistema recomendador. La justificación de la selección de datos debe, por lo tanto, estar intrínsecamente ligada a la justificación de la arquitectura del modelo propuesto.

Basado en el análisis comparativo, la recomendación principal es adoptar una **fuentes de datos híbrida**, con The WASABI Dataset como núcleo debido a su integridad multimodal nativa y su riqueza en metadatos contextuales [3](#) [77](#). Este núcleo debe ser enriquecido con características acústicas de baja nivel del Million Song Dataset (MSD) [53](#) y metadatos descriptivos (emocionales, temáticos) del dataset de Kaggle (1950-2019) [1](#), siempre que se pueda verificar su calidad. Esta fuente híbrida proporciona una representación de la música mucho más rica y completa que cualquier conjunto de datos individual.

Esta elección de datos influye directamente en la **representación de entrada** para el modelo Transformer. El modelo no procesará simples IDs de canción, sino que recibirá una secuencia de tokens que codifican la información de las tres modalidades. Se podría diseñar una arquitectura de entrada que incorpore:

1. **Embebimientos de Palabras para Letras:** Utilizando un tokenizer pre-entrenado (como BERT) para convertir las letras de cada canción en vectores densos.
2. **Vectores Numéricos para Características Acústicas:** Los valores de características como tempo, energy, valence, etc., extraídas tanto de WASABI como del MSD, se pasarían por una capa de embedding o se usarían directamente como características numéricas.
3. **Embebimientos de Categorías para Metadatos:** Los metadatos categóricos como género, década de lanzamiento o país de origen se representarían mediante embeddings de tablas de búsqueda.

La combinación de estos componentes formaría el tensor de entrada del Transformer. La estructura precisa de esta combinación dependerá de la estrategia de fusión multimodal elegida.

Las fuentes de investigación destacan varios enfoques para la fusión multimodal, que pueden aplicarse a los datos fusionados [11](#) [12](#) [62](#). La estrategia más prometedora y alineada con la filosofía de los Transformers es la **fusión basada en Cross-Attention**. A

diferencia de la fusión temprana (concatenar todas las características) o tardía (procesar cada modalidad por separado), la atención cruzada permite que una modalidad module o pese la información de otra. Por ejemplo, las características de las letras (intención, tema) podrían usarse como claves o preguntas para buscar información relevante en el espacio de características acústicas (tono, ritmo), y viceversa. Un estudio sobre la detección de humor musical multimodal ya demostró que la combinación de metadatos, letras y características acústicas puede mejorar significativamente la precisión [24](#). Un marco como el propuesto en TalkPlay, que reformula la tarea de recomendación como la generación de tokens de lenguaje grande, también apunta hacia la integración fluida de modalidades textuales y de contenido [16](#). Por lo tanto, la justificación del anteproyecto debe argumentar que la riqueza de la fuente de datos híbrida permite la implementación de una estrategia de fusión tan sofisticada, lo que potencialmente superaría a los modelos que tratan las modalidades de forma más rígida.

Finalmente, la arquitectura de datos sugerida debe seguir una narrativa de flujo de datos coherente, como se indica en el anteproyecto:

1. **Fuente de Datos:** La ingesta de datos de múltiples fuentes (WASABI, MSD, Kaggle) en un estado crudo.
2. **Data Lake:** El almacenamiento de estos datos heterogéneos en un Data Lakehouse (ej. Delta Lake sobre Amazon S3) para garantizar la escalabilidad, la versión y la trazabilidad [25](#).
3. **Procesamiento:** La ejecución de un pipeline de ETL/ELT automatizado para limpiar, mapear identificadores, resolver inconsistencias y enriquecer los datos, produciendo un conjunto de datos preparado para el entrenamiento.
4. **Modelado:** El entrenamiento de un modelo Transformer modular, con un encoder especializado para cada modalidad y una capa de fusión basada en Cross-Attention, sobre el conjunto de datos procesado.
5. **Producto de Datos:** La exportación del modelo entrenado y su despliegue en un servicio de inferencia de alto rendimiento (ej. FastAPI + Nvidia Triton Inference Server) para generar recomendaciones en tiempo real.
6. **Evaluación:** La validación empírica exhaustiva del modelo utilizando métricas de ranking estándar (Hit Rate@K, MRR, nDCG@K) y la comparación con modelos de referencia para demostrar la mejora de rendimiento gracias a la estrategia de datos y modelado propuesta.

En síntesis, la selección de una fuente de datos híbrida no es un mero detalle logístico, sino la piedra angular que sustenta toda la arquitectura del sistema. Justifica la complejidad del modelo Transformer y la implementación de una estrategia de fusión avanzada. Al documentar el camino desde la ingesta de datos heterogéneos hasta la producción de un modelo predictivo, el anteproyecto demuestra una comprensión profunda de los desafíos de la ingeniería de datos y la inteligencia artificial aplicada a la música, alineándose con los estándares de investigación de vanguardia.

Referencia

1. Music Dataset : 1950 to 2019 - Kaggle <https://www.kaggle.com/datasets/saurabhshahane/music-dataset-1950-to-2019>
2. [PDF] a case study of popular music data - HAL https://hal.science/tel-04932453v1/file/Manuscript_UCA_latex_template__TIKAT_%20%283%29.pdf
3. The WASABI Dataset: Cultural, Lyrics and Audio Analysis Metadata ... https://www.researchgate.net/publication/351988673_The_WASABI_Dataset_Cultural_Lyrics_and_Audio_Analysis_Metadata_About_2_Million_Popular_Commercially_Released_Songs
4. A review of representation and application scenarios of multi-modal ... <https://www.sciencedirect.com/science/article/pii/S0925231225022349/pdf>
5. (PDF) The Million Song Dataset. - ResearchGate https://www.researchgate.net/publication/220723656_The_Million_Song_Dataset
6. [PDF] The million song dataset challenge - Columbia University <https://www.ee.columbia.edu/~dpwe/pubs/McFeeBEL12-MSDC.pdf>
7. (PDF) The million song dataset - Academia.edu https://www.academia.edu/961705/The_million_song_dataset
8. [PDF] arXiv:1911.04827v1 [cs.LG] 12 Nov 2019 <https://arxiv.org/pdf/1911.04827>
9. MSD(Million Song Dataset) - OpenDataLab <https://opendatalab.com/OpenDataLab/MSD>
10. [PDF] exploring the WASABI music knowledge base - HAL https://hal.science/hal-03748134/file/WAC_2022_paper_15.pdf
11. [PDF] Socially Aware Music Recommendation: A Multi-Modal Graph ... <https://arxiv.org/pdf/2511.05497>
12. Enhancing Emotion Prediction in Music Through Acoustic and Lyric ... https://link.springer.com/chapter/10.1007/978-3-032-18846-5_32
13. A music recommender system based on compact convolutional ... <https://www.sciencedirect.com/science/article/abs/pii/S0957417424013393>
14. Transformer-Based Approach Towards Music Emotion Recognition ... https://www.researchgate.net/publication/350570898_Transformer-Based_Approach_Towards_Music_Emotion_Recognition_from_Lyrics

15. AI-Enabled Text-to-Music Generation: A Comprehensive Review of ... <https://www.mdpi.com/2079-9292/14/6/1197>
16. Multimodal Music Recommendation with Large Language Models <https://arxiv.org/html/2502.13713v3>
17. Integration of Text and Audio Features for Genre Classification in ... https://www.researchgate.net/publication/221397313_Integration_of_Text_and_Audio_Features_for_Genre_Classification_in_Music_Information_Retrieval
18. Exploiting the Power of Learnt Representations for Music Popularity ... <https://arxiv.org/html/2512.05508v1>
19. Nations of the Americas Chapter of the Association for ... <https://aclanthology.org/events/naacl-2025/>
20. Proceedings of the Annual Meeting of the Cognitive Science Society <https://escholarship.org/uc/cognitivesciencesociety>
21. A Survey on Cross-Modal Interaction Between Music and ... - arXiv <https://arxiv.org/html/2504.12796v1>
22. 1 Introduction - arXiv.org <https://arxiv.org/html/2504.12796v2>
23. [1809.07276] Music mood detection based on audio and lyrics with ... <https://ar5iv.labs.arxiv.org/html/1809.07276>
24. [PDF] arXiv:1808.10351v1 [cs.LG] 30 Aug 2018 <https://arxiv.org/pdf/1808.10351>
25. [PDF] The HaMSE Ontology: Using Semantic Technologies to support ... <https://arxiv.org/pdf/2202.05817>
26. Spotify Million Song Dataset - Kaggle <https://www.kaggle.com/datasets/notshrirang/spotify-million-song-dataset>
27. [PDF] deep analysis of lyrics structure and content - HAL theses <https://theses.hal.science/tel-03135082/file/2020COAZ4017.pdf>
28. [PDF] Artificial Intelligence to Extract, Analyze and Generate Knowledge ... <https://inria.hal.science/tel-03084380/file/manuscript.pdf>
29. Music Dataset: Lyrics and Metadata from 1950 to 2019 <https://data.mendeley.com/datasets/3t9vbwxgr5/2>
30. Why are song lyrics becoming simpler? a time series analysis ... - PMC <https://pmc.ncbi.nlm.nih.gov/articles/PMC7806124/>
31. [PDF] A Corpus Linguistic Perspective on Contemporary German Pop ... <https://aclanthology.org/2020.lrec-1.105.pdf>
32. Multi-Modal Song Mood Detection with Deep Learning - PMC <https://pmc.ncbi.nlm.nih.gov/articles/PMC8838547/>

33. Music emotion recognition using convolutional long short term ... <https://www.sciencedirect.com/science/article/pii/S2215098620342385>
34. Applications and Advances of Artificial Intelligence in Music ... - arXiv <https://arxiv.org/html/2409.03715v1>
35. Using Deep Learning to Recognize Therapeutic Effects of Music ... <https://www.mdpi.com/1424-8220/23/2/986>
36. Associations between lyric and musical depth in Chinese songs ... <https://onlinelibrary.wiley.com/doi/full/10.1002/pchj.785>
37. (PDF) Music Emotion Classification: A Literature Review https://www.researchgate.net/publication/384586090_Music_Emotion_Classification_A_Literature_Review
38. Surveying More Than Two Decades of Music Information Retrieval ... <https://dl.acm.org/doi/full/10.1145/3688398>
39. "RaagaDhvani: A novel augmented multi-feature dataset: Advancing ... <https://www.sciencedirect.com/science/article/pii/S2352340925010789>
40. Human Language Technologies (Volume 1: Long Papers) <https://aclanthology.org/volumes/2025.naacl-long/>
41. Capstone-Assignment - RPubS <https://rpubs.com/BushraT/1075426>
42. KDD: Knowledge Discovery and Data Mining - ACM Digital Library <https://dl.acm.org/doi/proceedings/10.1145/3711896?tocHeading=heading2>
43. [PDF] The WASABI Song Corpus and Knowledge Graph for Music Lyrics ... https://hal.science/hal-03812106v1/file/WASABI_NLP_Corpus__LRE_journal%20%281%29.pdf
44. The WASABI song corpus and knowledge graph for music lyrics ... https://www.researchgate.net/publication/362170185_The_WASABI_song_corpus_and_knowledge_graph_for_music_lyrics_analysis
45. Flutter Distribution Dashboard Spec Ar | PDF - Scribd <https://www.scribd.com/document/929106571/Flutter-Distribution-Dashboard-Spec-Ar>
46. Proceedings of the Twelfth Language Resources and Evaluation ... <https://aclanthology.org/volumes/2020.lrec-1/>
47. [PDF] Basic Concept of Biotechnology - ResearchGate https://www.researchgate.net/profile/Chandrashekara-Kn/publication/271908784_Basic_Concept_of_Biotechnology/links/556fd7a508aec226830ab89c/Basic-Concept-of-Biotechnology.pdf
48. 333333 23135851162 the 13151942776 of 12997637966 <https://www.cs.princeton.edu/courses/archive/spring18/cos226/assignments/autocomplete/testing/words-333333.txt>

49. [PDF] Content-driven Music Recommendation - arXiv <https://arxiv.org/pdf/2107.11803>
50. Appl. Sci., Volume 12, Issue 18 (September-2 2022) – 473 articles <https://www.mdpi.com/2076-3417/12/18>
51. Spell Checker using Word2vec - Kaggle <https://www.kaggle.com/code/mlwhiz/spell-checker-using-word2vec>
52. Taskpane Dict | PDF - Scribd <https://www.scribd.com/document/615646225/Taskpane-Dict>
53. [PDF] Content-driven Music Recommendation: Evolution, State of the Art ... https://www.researchgate.net/publication/353479135_Content-driven_Music_Recommendation_Evolution_State_of_the_Art_and_Challenges/fulltext/60ff7ba21e95fe241a8e8a22/Content-driven-Music-Recommendation-Evolution-State-of-the-Art-and-Challenges.pdf
54. Music Dataset: Lyrics and Metadata from 1950 to 2019 <https://data.mendeley.com/datasets/3t9vbwxgr5/3>
55. Music Dataset : 1950 to 2019 - Kaggle <https://www.kaggle.com/datasets/saurabhshahane/music-dataset-1950-to-2019/code>
56. A Troubling Analysis of Reproducibility and Progress in ... <https://dl.acm.org/doi/fullHtml/10.1145/3434185>
57. Proceedings of the 33rd ACM International Conference on Multimedia <https://dl.acm.org/doi/proceedings/10.1145/3746027?tocHeading=heading4>
58. Companion Proceedings of the ACM on Web Conference 2025 <https://dl.acm.org/doi/proceedings/10.1145/3701716?tocHeading=heading2>
59. Tokenizer On DataSet - Kaggle <https://www.kaggle.com/code/shubhamgupta012/tokenizer-on-dataset>
60. [PDF] Transformers with multi-modal features and post-fusion context for e ... <https://arxiv.org/pdf/2107.05124>
61. Creating musical features using multi-faceted, multi-task encoders ... <https://www.nature.com/articles/s41598-023-36714-z>
62. (PDF) Multimodal Fusion Based Attentive Networks for Sequential ... https://www.researchgate.net/publication/357138617_Multimodal_Fusion_Based_Attentive_Networks_for_Sequential_Music_Recommendation
63. [PDF] From wikis to tube guitar amplifier simulations, the universal web ... <https://univ-cotedazur.hal.science/tel-01963301v1/file/HDR%20Michel%20Buffa%20finale.pdf>
64. Million Song Dataset Challenge | Kaggle <https://www.kaggle.com/competitions/msdchallenge/discussion/1860>

65. [PDF] THE MILLION SONG DATASET - Columbia University <https://www.ee.columbia.edu/~dpwe/pubs/BertEWL11-msd.pdf>
66. Million Song Dataset Challenge | Kaggle <https://www.kaggle.com/c/msdchallenge/discussion/2365>
67. Content-driven Music Recommendation: Evolution, State of the Art ... https://www.researchgate.net/publication/353479135_Content-driven_Music_Recommendation_Evolution_State_of_the_Art_and_Challenges
68. Rane Audio Reference | PDF | Analog To Digital Converter - Scribd <https://www.scribd.com/document/105800662/Rane-Audio-Reference>
69. Music Dataset : 1950 to 2019 - Kaggle <https://www.kaggle.com/datasets/saurabhshahane/music-dataset-1950-to-2019/data>
70. Music Dataset : 1950 to 2019 | Kaggle <https://www.kaggle.com/saurabhshahane/music-dataset-1950-to-2019/metadata>
71. Investigating country-specific music preferences ... - Springer Nature <https://link.springer.com/article/10.1007/s13735-017-0118-y>
72. [PDF] Audio-based Musical Version Identification: Elements and Challenges <https://arxiv.org/pdf/2109.02472>
73. (PDF) Song Hit Prediction: Predicting Billboard Hits Using Spotify Data https://www.academia.edu/145146932/Song_Hit_Prediction_Predicting_Billboard_Hits_Using_Spotify_Data
74. 10.1007@978 3 030 49161 1 | PDF | Artificial Intelligence - Scribd <https://www.scribd.com/document/489211602/10-1007-978-3-030-49161-1>
75. Probing Cultural Signals in Large Language Models through Author ... <https://arxiv.org/html/2603.16749v1>
76. Learning MIDI embeddings for reliable prediction of symbolic music ... <https://journals.sagepub.com/doi/10.3233/SW-210446>
77. D2.4: Methods for interlinking knowledge graphs (V1.0) https://www.academia.edu/165567412/D2_4_Methods_for_interlinking_knowledge_graphs_V1_0_
78. [PDF] informed content estimation and audio source separation - HAL theses https://theses.hal.science/tel-03253128v2/file/MESEGUER_BROCAL_2020.pdf
79. Top 100 Songs & Lyrics By Year 1959 - 2023 (USA) - Kaggle <https://www.kaggle.com/datasets/brianblakely/top-100-songs-and-lyrics-from-1959-to-2019>
80. Music Dataset: Song Information and Lyrics - Kaggle <https://www.kaggle.com/datasets/suraj520/music-dataset-song-information-and-lyrics>
81. Top US Songs from 1950 to 2019 lyrics EDA | Kaggle <https://www.kaggle.com/code/stefancomanita/top-us-songs-from-1950-to-2019-lyrics-eda>

82. Future of AI and Digital Currency in India | PDF - Scribd <https://www.scribd.com/document/974737117/Mint-Mumbai-31-12-2025>
83. Transformer-Based Multimodal Framework for Music Similarity ... <https://www.semanticscholar.org/paper/19455be485e31b102ded019828ddb6a6993d4100>
84. [PDF] The Million Song Dataset - Semantic Scholar <https://www.semanticscholar.org/paper/The-Million-Song-Dataset-Bertin-Mahieux-Ellis/5aaf311172b9778d78f6904fbe40124c63463b57>
85. Hybrid music recommendation with graph neural networks <https://link.springer.com/article/10.1007/s11257-024-09410-4>
86. The Million Song Dataset - Columbia Academic Commons <https://academiccommons.columbia.edu/doi/10.7916/D8NZ8J07>
87. Million Song Dataset. Columbia University. <http://labrosa.ee.columbia.edu/millionsong> ... https://www.researchgate.net/publication/270948896_Million_Song_Dataset_Columbia_University_httplabrosaee.columbia.edu/millionsong
88. [PDF] Music Genre Classification with the Million Song Dataset <https://www.ee.columbia.edu/~dliang/files/FINAL.pdf>
89. (PDF) Improving genre annotations for the million song dataset https://www.researchgate.net/publication/323826597_Improving_genre_annotations_for_the_million_song_dataset
90. An Exploration of Mood Classification in the Million Songs Dataset https://www.researchgate.net/publication/280733696_An_Exploration_of_Mood_Classification_in_the_Million_Songs_Dataset
91. Derivative Media: The Financialization of Film, Television, and ... <https://escholarship.org/uc/item/69w0v6n3>
92. [PDF] UCLA Electronic Theses and Dissertations - eScholarship.org <https://escholarship.org/content/qt69w0v6n3/qt69w0v6n3.pdf>
93. Million Song Dataset Million Song Dataset | Datasets | HyperAI <https://hyper.ai/en/datasets/5693>
94. LNCS 13324 Culture and Computing - Springer Nature <https://link.springer.com/content/pdf/10.1007/978-3-031-05434-1.pdf>
95. MultiMedia Modeling - Springer Nature <https://link.springer.com/content/pdf/10.1007/978-3-319-51814-5.pdf>
96. Icrtcsda'25 - Phase 3 | PDF | Neuron | Brain - Scribd <https://www.scribd.com/document/848682038/Icrtcsda-25-Phase-3>
97. [PDF] Emotion-based Analysis and Classification of Audio Music https://www.researchgate.net/profile/Renato-Panda/publication/332329014_Emotion-based_Analysis_and_Classification_of_Audio_Music/links/

5cf04b95299bf1fb184b95cd/Emotion-based-Analysis-and-Classification-of-Audio-Music.pdf

98. Sound, Music, and Motion - Springer Nature <https://link.springer.com/content/pdf/10.1007/978-3-319-12976-1.pdf>
99. Spotify 2019 Dataset - Kaggle <https://www.kaggle.com/code/chitreshkr/spotify-2019-dataset>
100. Starter: Music Dataset : 1950 to 2019 532159c9-c - Kaggle <https://www.kaggle.com/code/kerneler/starter-music-dataset-1950-to-2019-532159c9-c>
101. 500K+ Spotify Songs with Lyrics, Emotions & More - Kaggle <https://www.kaggle.com/datasets/devdope/900k-spotify>